


NutriBot: Asistente de Nutrición Deportiva

RAG Avanzado y Agente Autónomo
con Herramientas



Python 3.11 — Flask — Claude 3.5 Haiku — FAISS — SQLite

keep coding

El Desafío: Precisión vs. Disponibilidad



Nutricionista Humano

Coste: **Alto**
(50-150€/sesión)

Disponibilidad:
Limitada

Problema: **No escalable**

LLMs Genéricos

Coste: Bajo/Nulo

Disponibilidad:
Inmediata (24/7)

Problema:
Alucinaciones, Sin Memoria, Genérico



Insight: En nutrición deportiva, un ratio de macros alucinado no es un error menor; es un fallo crítico del producto.

La Solución: NutriBot

Un sistema que combina conocimiento verificado con ejecución autónoma.

1. Fundamentación (RAG)



990 chunks verificados.
Elimina alucinaciones.

2. Memoria de Estado



Persistencia SQLite.
Personalización real.

3. Agente Autónomo




5 herramientas de cálculo.
Precisión matemática.

**Solicitud
Usuario**

Cerebro NutriBot


**Respuesta
Precisa**

Arquitectura del Sistema




Orquestación centralizada que separa la seguridad, la lógica de negocio y la inferencia.

El "Cerebro": Bucle del Agente y Herramientas




Estrategia RAG: Retrieval en Dos Etapas



El CrossEncoder evalúa la relevancia real query-documento, filtrando información semánticamente cercana pero irrelevante.

Decisión Clave #1: Embeddings Multilingües


English Embeddings
(MiniLM-L6)



Problem / Solution


+166%
Mejora en Context Recall

Multilingual Embeddings
(paraphrase-multilingual-MiniLM-L12)




En RAG no anglófono, los embeddings multilingües son un requisito obligatorio.

Decisión Clave #2: API vs. Fine-Tuning




Seguridad: Defensa en Profundidad



4 capas independientes filtran inputs maliciosos
antes de la lógica core.



Persistencia de Datos y Estado



SQLite Schema

Onboarding Determinista (8 Pasos)



Garantiza datos estructurados antes de que la IA tome el control.


Evaluación Cuantitativa (RAGas)

	Métrica	Baseline	Sistema Final	Mejora
1	Context Precision	0.28	0.77	+169.7%
2	Context Recall	0.25	0.68	+166.0%
3	Answer Relevancy	0.39	0.84	+113.4%
4	Faithfulness	0.39	0.67	+71.5%

El reranking y los embeddings multilingües transformaron la fiabilidad del sistema.



Roadmap y Mejoras Futuras



SCHEMATIC: ROADMAP_MEJORAS_FUTURAS


REV: 1.0

DATE: OCT 2024



NotebookLM

EL Stack Tecnológico



Conclusiones y Aprendizajes



Embeddings

En RAG no inglés, los modelos multilingües son obligatorios.




Retrieval

El Reranking (**CrossEncoder**) justifica su latencia con **+169%** de precisión.



Arquitectura

La orquestación (Guardrails + Agente) supera al tamaño del modelo.



Call to Action



Código Fuente
Disponible



Conectar


keep coding



SCHEMATIC: CONCLUSIONES_APRENDIZAJES

REV: 1.0

DATE: OCT 2024



NotebookLM